

# 强化学习2022

## 第8节

涉及知识点：

基于神经网络的策略梯度、A3C、确定性梯度策略、深度确定性策略梯度、TRPO、PPO



## 深度策略梯度

# 课程大纲

## 强化学习基础部分

1. 强化学习、探索与利用
2. MDP和动态规划
3. 值函数估计
4. 无模型控制方法
5. 规划与学习
6. 参数化的值函数和策略
7. 深度强化学习价值方法
8. 深度强化学习策略方法

## 强化学习前沿部分


9. 基于模型的深度强化学习
10. 离线强化学习
11. 模仿学习
12. 参数化动作空间
13. 多智能体强化学习基础
14. 多智能体强化学习前沿
15. 强化学习的应用
16. 技术与交流与回顾

# 深度强化学习

标准 (传统)  
强化学习



深度强化学习



- 直面理解：深度学习+强化学习
- 深度强化学习使强化学习算法能够以端到端的方式解决复杂问题
- 真正让强化学习有能力完成实际决策任务
- 比强化学习和深度学习各自都更加难以驯化
- 基于价值函数的深度强化学习
  - DQN：一次输入多个行动Q值输出、目标网络、随机采样经验
  - Double DQN：解耦合行动选择和价值估计、解决DQN过高估计问题
  - Dueling DQN：精细捕捉价值和行动的细微关联、多种advantage函数建模

# 深度强化学习的分类

---

## □ 基于价值的方法

- 深度Q网络及其扩展

## □ 基于随机策略的方法

- 基于神经网络的策略梯度，信任区域策略优化（TRPO），近端策略优化（PPO），A3C

## □ 基于确定性策略的方法

- 确定性策略梯度（DPG），DDPG



# 基于神经网络的策略梯度

## 复习：策略梯度定理

- 策略梯度定理把似然比的推导过程泛化到多步马尔可夫决策过程
  - 用长期的价值函数  $Q^{\pi_{\theta}}(s, a)$  代替前面的瞬时奖励  $r_{sa}$
- 策略梯度定理涉及
  - 起始状态目标函数  $J_1$ ，平均奖励目标函数  $J_{avR}$ ，和平均价值目标函数  $J_{avV}$
- 定理
  - 对任意可微的策略  $\pi_{\theta}(a|s)$ ，任意策略的目标函数  $J = J_1, J_{avR}, J_{avV}$ ，其策略梯度是

$$\frac{\partial J(\theta)}{\partial \theta} = \mathbb{E}_{\pi_{\theta}} \left[ \frac{\partial \log \pi_{\theta}(a|s)}{\partial \theta} Q^{\pi_{\theta}}(s, a) \right]$$

详细证明过程请参考 Rich Sutton's Reinforcement Learning: An Introduction (2<sup>nd</sup> Edition) 第13章

# 策略网络的梯度

- 对于随机策略，一般采样到每一个行动的概率由Softmax实现

$$\pi_{\theta}(a|s) = \frac{e^{f_{\theta}(s,a)}}{\sum_{a'} e^{f_{\theta}(s,a')}}$$

- 其中 $f_{\theta}(s, a)$ 是对状态-行动对的打分函数，由 $\theta$ 参数化，这可以通过一个神经网络来实现

- 其log形式的梯度为

$$\begin{aligned} \frac{\partial \log \pi_{\theta}(a|s)}{\partial \theta} &= \frac{\partial f_{\theta}(s, a)}{\partial \theta} - \frac{1}{\sum_{a'} e^{f_{\theta}(s,a')}} \sum_{a''} e^{f_{\theta}(s,a'')} \frac{\partial f_{\theta}(s, a'')}{\partial \theta} \\ &= \frac{\partial f_{\theta}(s, a)}{\partial \theta} - \mathbb{E}_{a' \sim \pi_{\theta}(a'|s)} \left[ \frac{\partial f_{\theta}(s, a')}{\partial \theta} \right] \end{aligned}$$

# 策略网络的梯度

## □ 其log梯度形式

$$\frac{\partial \log \pi_{\theta}(a|s)}{\partial \theta} = \frac{\partial f_{\theta}(s, a)}{\partial \theta} - \mathbb{E}_{a' \sim \pi_{\theta}(a'|s)} \left[ \frac{\partial f_{\theta}(s, a')}{\partial \theta} \right]$$

## □ 策略网络的梯度为

$$\begin{aligned} \frac{\partial J(\theta)}{\partial \theta} &= \mathbb{E}_{\pi_{\theta}} \left[ \frac{\partial \log \pi_{\theta}(a|s)}{\partial \theta} Q^{\pi_{\theta}}(s, a) \right] \\ &= \mathbb{E}_{\pi_{\theta}} \left[ \underbrace{\left( \frac{\partial f_{\theta}(s, a)}{\partial \theta} \right)}_{\text{反向梯度传播}} - \mathbb{E}_{a' \sim \pi_{\theta}(a'|s)} \underbrace{\left[ \frac{\partial f_{\theta}(s, a')}{\partial \theta} \right]}_{\text{反向梯度传播}} \right] Q^{\pi_{\theta}}(s, a) \end{aligned}$$



# 策略梯度和Q学习的对比

- Q 学习算法学习一个由  $\theta$  作为参数的函数  $Q_\theta(s, a)$ 
  - 优化目标为最小化TD error

$$J(\theta) = \mathbb{E}_{\pi'} \left[ \frac{1}{2} \left( r_t + \gamma \max_{a'} Q_{\theta'}(s_{t+1}, a') - Q_\theta(s_t, a_t) \right)^2 \right]$$

- 更新方程

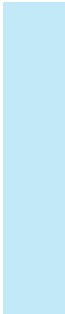
$$\begin{aligned} \theta &\leftarrow \theta - \alpha \frac{\partial J(\theta)}{\partial \theta} \\ &= \theta + \alpha \mathbb{E}_{\pi'} \left[ \left( r_t + \gamma \max_{a'} Q_{\theta'}(s_{t+1}, a') - Q_\theta(s_t, a_t) \right) \frac{\partial Q_\theta(s, a)}{\partial \theta} \right] \end{aligned}$$

- 策略梯度学习一个由  $\theta$  作为参数的策略  $\pi_\theta(a|s)$ 
  - 优化目标直接为策略的价值 (比Q学习更加直接)

$$\max_{\theta} J(\theta) = \mathbb{E}_{\pi_\theta} [\pi_\theta(a|s) A^{\pi_\theta}(s, a)]$$

- 更新方程

$$\theta \leftarrow \theta + \alpha \frac{\partial J(\theta)}{\partial \theta} = \theta + \alpha \mathbb{E}_{\pi_\theta} \left[ \frac{\partial \log \pi_\theta(a|s)}{\partial \theta} A^{\pi_\theta}(s, a) \right]$$



**A3C**

# 复习: Actor-Critic

## □ Actor-Critic的思想

- REINFORCE策略梯度方法: 使用蒙特卡罗采样直接估计 $(s_t, a_t)$ 的值 $G_t$
- 为什么不建立一个可训练的值函数 $Q_\phi$ 来完成这个估计过程?

## □ 演员 (Actor) 和评论家 (Critic)

演员  $\pi_\theta(a|s)$

采取动作使评论家满意的策略



评论家  $Q_\phi(s, a)$

学会准确估计演员策略所采取动作价值的值函数


# 复习A2C：优势Actor-Critic

□ 思想：通过减去一个基线函数来标准化评论家的打分

- 更多信息指导：降低较差动作概率，提高较优动作概率
- 进一步降低方差

□ 优势函数 (Advantage Function)

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s)$$




# A3C: 异步A2C方法

- A3C代表了异步优势动作评价（Asynchronous Advantage Actor Critic）
  - 异步（Asynchronous）：因为算法涉及并行执行一组环境
  - 优势（Advantage）：因为策略梯度的更新使用优势函数
  - 动作评价（Actor Critic）：因为这是一种动作评价（actor-critic）方法，它涉及一个在学得的状态值函数帮助下进行更新的策略

$$\nabla_{\theta'} \log \pi(a_t | s_t; \theta') A(s_t, a_t; \theta_v)$$

$$A(s_t, a_t; \theta_v) = \sum_{i=0}^{k-1} \gamma^i r_{t+i} + \gamma^k V(s_{t+k}; \theta_v) - V(s_t; \theta_v)$$

# A3C: 异步A2C方法



# A3C算法

---

**Algorithm S3** Asynchronous advantage actor-critic - pseudocode for each actor-learner thread.

---

*// Assume global shared parameter vectors  $\theta$  and  $\theta_v$  and global shared counter  $T = 0$*

*// Assume thread-specific parameter vectors  $\theta'$  and  $\theta'_v$*

Initialize thread step counter  $t \leftarrow 1$

**repeat**

Reset gradients:  $d\theta \leftarrow 0$  and  $d\theta_v \leftarrow 0$ .

Synchronize thread-specific parameters  $\theta' = \theta$  and  $\theta'_v = \theta_v$

$t_{start} = t$

Get state  $s_t$

**repeat**

Perform  $a_t$  according to policy  $\pi(a_t|s_t; \theta')$

Receive reward  $r_t$  and new state  $s_{t+1}$

$t \leftarrow t + 1$

$T \leftarrow T + 1$

**until** terminal  $s_t$  **or**  $t - t_{start} == t_{max}$

$R = \begin{cases} 0 & \text{for terminal } s_t \\ V(s_t, \theta'_v) & \text{for non-terminal } s_t // \text{ Bootstrap from last state} \end{cases}$

**for**  $i \in \{t - 1, \dots, t_{start}\}$  **do**

$R \leftarrow r_i + \gamma R$

Accumulate gradients wrt  $\theta'$ :  $d\theta \leftarrow d\theta + \nabla_{\theta'} \log \pi(a_i|s_i; \theta')(R - V(s_i; \theta'_v))$

Accumulate gradients wrt  $\theta'_v$ :  $d\theta_v \leftarrow d\theta_v + \partial (R - V(s_i; \theta'_v))^2 / \partial \theta'_v$


**end for**

Perform asynchronous update of  $\theta$  using  $d\theta$  and of  $\theta_v$  using  $d\theta_v$ .

**until**  $T > T_{max}$

---

# A3C对比实验



a single Nvidia K40 GPU while the asynchronous methods were trained using 16 CPU cores

Method	Training Time	Mean	Median	
DQN	8 days on GPU	121.9%	47.5%	Nvidia K40 GPUs
Gorila	4 days, 100 machines	215.2%	71.3%	
D-DQN	8 days on GPU	332.9%	110.9%	
Dueling D-DQN	8 days on GPU	343.8%	117.1%	
Prioritized DQN	8 days on GPU	463.6%	127.6%	
A3C, FF	1 day on CPU	344.1%	68.2%	16 CPU cores and no GPU
A3C, FF	4 days on CPU	496.8%	116.6%	
A3C, LSTM	4 days on CPU	623.0%	112.6%	

Mean and median human-normalized scores on 57 Atari games





# 确定性策略梯度

# 深度强化学习的分类

---

## □ 基于价值的方法

- 深度Q网络及其扩展

## □ 基于随机策略的方法

- 使用神经网络的策略梯度，自然策略梯度，信任区域策略优化（TRPO），近端策略优化（PPO），A3C

## □ 基于确定性策略的方法

- 确定性策略梯度（DPG），DDPG

# 随机策略与确定性策略

## □ 随机策略

对于离散动作

$$\pi(a|s; \theta) = \frac{\exp\{Q_\theta(s, a)\}}{\sum_{a'} \exp\{Q_\theta(s, a')\}}$$

对于连续动作

$$\pi(a|s; \theta) \propto \exp\left\{\left(a - \mu_\theta(s)\right)^2\right\}$$

## □ 确定性策略

对于离散动作

$$\pi(s; \theta) = \arg \max_a Q_\theta(s, a) \quad \text{不可微}$$

对于连续动作

$$a = \pi(s; \theta) \quad \text{可微}$$

# 确定性策略梯度

- 用于估计状态-动作值的评论家 (critic) 模块

$$Q^w(s, a) \simeq Q^\pi(s, a)$$

$$L(w) = \mathbb{E}_{s \sim \rho^\pi, a \sim \pi_\theta} \left[ (Q^w(s, a) - Q^\pi(s, a))^2 \right]$$

- 确定性策略

- 确定性策略梯度定理


$$J(\pi_\theta) = \mathbb{E}_{s \sim \rho^\pi} [Q^w(s, a)]$$

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_{s \sim \rho^\pi} [\nabla_\theta \pi_\theta(s) \cdot \nabla_a Q^w(s, a)|_{a=\pi_\theta(s)}]$$


在线策略

链式法则

# 确定性策略梯度实验效果




(a) Mountain Car



(b) Pendulum

- COPDAC-Q: 当时论文提出的确定性策略梯度 (off-policy)
- SAC: 随机梯度策略 (on-policy)
- OffPAC-TD: 随机梯度策略 (off-policy)



(c) 2D Puddle World

# 深度确定性策略梯度



# DDPG：深度确定性策略梯度

## □ 对于确定性策略的梯度

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{s \sim \rho^{\pi}} [\nabla_{\theta} \pi_{\theta}(s) \cdot \nabla_a Q^w(s, a)|_{a=\pi_{\theta}(s)}]$$

- 在实际应用中，这种带有神经函数近似器的actor-critic方法在面对有挑战性的问题时是不稳定的
- 深度确定性策略梯度（DDPG）给出了在确定性策略梯度（DPG）基础上的解决方法
  - 经验重放（离线策略）
  - 目标网络
  - 在动作输入前批标准化Q网络
  - 添加连续噪声

# DDPG: 深度确定性策略梯度

## Algorithm 1 DDPG algorithm

Randomly initialize critic network  $Q(s, a|\theta^Q)$  and actor  $\mu(s|\theta^\mu)$  with weights  $\theta^Q$  and  $\theta^\mu$ .

Initialize target network  $Q'$  and  $\mu'$  with weights  $\theta^{Q'} \leftarrow \theta^Q, \theta^{\mu'} \leftarrow \theta^\mu$

Initialize replay buffer  $R$

**for** episode = 1, M **do**

Initialize a random process  $\mathcal{N}$  for action exploration

Receive initial observation state  $s_1$

**for** t = 1, T **do**

Select action  $a_t = \mu(s_t|\theta^\mu) + \mathcal{N}_t$  according to the current policy and exploration noise

Execute action  $a_t$  and observe reward  $r_t$  and observe new state  $s_{t+1}$

Store transition  $(s_t, a_t, r_t, s_{t+1})$  in  $R$

Sample a random minibatch of  $N$  transitions  $(s_i, a_i, r_i, s_{i+1})$  from  $R$

Set  $y_i = r_i + \gamma Q'(s_{i+1}, \mu'(s_{i+1}|\theta^{\mu'})|\theta^{Q'})$

Update critic by minimizing the loss:  $L = \frac{1}{N} \sum_i (y_i - Q(s_i, a_i|\theta^Q))^2$

Update the actor policy using the sampled gradient:

目标critic网络

$$\nabla_{\theta^\mu} \mu|_{s_i} \approx \frac{1}{N} \sum_i \nabla_a Q(s, a|\theta^Q)|_{s=s_i, a=\mu(s_i)} \nabla_{\theta^\mu} \mu(s|\theta^\mu)|_{s_i}$$

目标actor网络

Update the target networks:

$$\theta^{Q'} \leftarrow \tau \theta^Q + (1 - \tau) \theta^{Q'}$$

$$\theta^{\mu'} \leftarrow \tau \theta^\mu + (1 - \tau) \theta^{\mu'}$$

**end for**

**end for**

更新actor网络


离线策略

更新critic网络 ( $a_i$ 带有噪声)

动作上的噪声



# 深度确定性策略梯度实验



## □ 确定性策略梯度 (DPG) 及其变种在一系列经典强化学习任务中的表现曲线

- 浅灰色：使用批标准化的原始DPG算法
- 暗灰色：使用目标网络的原始DPG算法
- 绿色：同时使用目标网络和批标准化
- 蓝色：使用仅像素作为输入的目标网络

## □ 目标网络至关重要



# 信任区域策略优化 TRPO

# 目录

## Contents

- 01 策略梯度的缺点
- 02 TRPO算法
- 03 策略改进的单调性保证
- 04 实验结果



01

## 策略梯度的缺点

# 策略梯度算法回顾

## □ 蒙特卡洛策略梯度 (REINFORCE) 算法

initialize  $\theta$  arbitrarily

for each episode  $\{s_1, a_1, r(s_1, a_1), \dots, s_T, a_T, r(s_T, a_T)\} \sim \pi_\theta$  do

for  $t = 1$  to  $T$  do

$$\theta \leftarrow \theta + \alpha \frac{\partial}{\partial \theta} \log \pi_\theta(a_t | s_t) G_t$$

end for

end for

return  $\theta$

## 相关定义

□  $s_t, a_t, r(s_t, a_t)$ :  $t$  时刻的状态, 动作和奖励

□  $\pi_\theta, \theta$ : 使用的策略, 表示策略所使用的参数

□  $G_t$ : 累计奖励


□  $\alpha$ : 步长

# 策略梯度的缺点

## 步长

### □ 步长难以确定

- 采集到的数据的分布会随策略的更新而变化。
- 较差的步长产生的影响大。





# 策略梯度的优化目标

## □ 优化目标的两种形式

- 第一种:  $J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}(\tau)} [\sum_t \gamma^t r(s_t, a_t)]$
- 因为  $V^{\pi_{\theta}}(s) = \mathbb{E}_{a \sim \pi_{\theta}(s)} [Q^{\pi_{\theta}}(s, a)] = \mathbb{E}_{a \sim \pi_{\theta}(s)} [\mathbb{E}_{\tau \sim p_{\theta}(\tau)} [\sum_{t=k}^{\infty} \gamma^{t-k} r(s_t, a_t)]]$
- 所以优化目标的第二种形式是:  $J(\theta) = \mathbb{E}_{s_0 \sim p_{\theta}(s_0)} [V^{\pi_{\theta}}(s_0)]$

## 相关定义

- $\tau$ : 轨迹
- $s_0$ : 初始状态
- $s_t, a_t, r(s_t, a_t)$ :  $t$  时刻的状态, 动作和奖励
- $\pi_{\theta}$ : 使用的策略
- $\theta$ : 表示策略所使用的参数
- $Q^{\pi_{\theta}}$  和  $V^{\pi_{\theta}}$ : 策略  $\pi_{\theta}$  下的  $Q$  值与状态值函数



# 优化目标的优化量

$$J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}(\tau)} [\sum_t \gamma^t r(s_t, a_t)]$$
$$J(\theta) = \mathbb{E}_{s_0 \sim p_{\theta}(s_0)} [V^{\pi_{\theta}}(s_0)]$$

初始状态的分布与 $\theta$ 无关

$$\begin{aligned} J(\theta') - J(\theta) &= J(\theta') - \mathbb{E}_{s_0 \sim p(s_0)} [V^{\pi_{\theta}}(s_0)] \\ &= J(\theta') - \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} [V^{\pi_{\theta}}(s_0)] \\ &= J(\theta') - \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t V^{\pi_{\theta}}(s_t) - \sum_{t=1}^{\infty} \gamma^t V^{\pi_{\theta}}(s_t) \right] \\ &= J(\theta') + \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t (\gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)) \right] \\ &= \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right] + \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t (\gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)) \right] \\ &= \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t (r(s_t, a_t) + \gamma V^{\pi_{\theta}}(s_{t+1}) - V^{\pi_{\theta}}(s_t)) \right] \\ &= \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t A^{\pi_{\theta}}(s_t, a_t) \right] \end{aligned}$$

$J(\theta')$ 的定义

$A^{\pi_{\theta}}(s_t, a_t) = Q^{\pi_{\theta}}(s_t, a_t) - V^{\pi_{\theta}}(s_t)$

不方便采样

# 使用重要性采样

## □ 使用重要性采样 (Importance Sampling)

$$\begin{aligned} J(\theta') - J(\theta) &= \mathbb{E}_{\tau \sim p_{\theta'}(\tau)} \left[ \sum_{t=0}^{\infty} \gamma^t A^{\pi_{\theta}}(s_t, a_t) \right] \\ &= \sum_t \mathbb{E}_{s_t \sim p_{\theta'}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta'}(a_t|s_t)} [\gamma^t A^{\pi_{\theta}}(s_t, a_t)]] \\ &= \sum_t \mathbb{E}_{s_t \sim p_{\theta'}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t|s_t)} \left[ \frac{\pi_{\theta'}(a_t|s_t)}{\pi_{\theta}(a_t|s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t) \right]] \end{aligned}$$

$$\begin{aligned} A^{\pi_{\theta}}(s_t, a_t) \\ = Q^{\pi_{\theta}}(s_t, a_t) - V^{\pi_{\theta}}(s_t) \end{aligned}$$


仍然是  $p_{\theta'}$   
(近似操作)

重要性采样

# 忽略状态分布的差异

□ 当策略更新前后的变化较小时，可以令  $p_\theta(s_t) \approx p_{\theta'}(s_t)$ 。

- 假设使用确定性策略，当  $\pi_{\theta'}(s_t) \neq \pi_\theta(s_t)$  的概率小于  $\epsilon$  时
- 或者假设使用随机策略，当  $a' \sim \pi_{\theta'}(\cdot | s_t) \neq a \sim \pi_\theta(\cdot | s_t)$  的概率小于  $\epsilon$  时
- $p_{\theta'}(s_t) = (1 - \epsilon)^t p_\theta(s_t) + (1 - (1 - \epsilon)^t) p_{mistake}(s_t)$
- $|p_{\theta'}(s_t) - p_\theta(s_t)| = (1 - (1 - \epsilon)^t) |p_{mistake}(s_t) - p_\theta(s_t)| \leq 2(1 - (1 - \epsilon)^t) \leq 2\epsilon t$


$$(1 - \epsilon)^t \geq 1 - \epsilon t \text{ for } \epsilon \in [0, 1]$$

$$J(\theta') - J(\theta) \approx \sum_t \mathbb{E}_{s_t \sim p_{\theta}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t | s_t)} [\frac{\pi_{\theta'}(a_t | s_t)}{\pi_{\theta}(a_t | s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t)]]$$

# 约束策略的变化

- 使用KL散度约束策略更新的幅度

$$\theta' \leftarrow \arg \max_{\theta'} \sum_t \mathbb{E}_{s_t \sim p_{\theta}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t|s_t)} [\frac{\pi_{\theta'}(a_t|s_t)}{\pi_{\theta}(a_t|s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t)]]$$

*such that*  $\mathbb{E}_{s_t \sim p(s_t)} [D_{KL}(\pi_{\theta'}(a_t|s_t) \parallel \pi_{\theta}(a_t|s_t))] \leq \epsilon$

- 实际多使用constraint violate as penalty

$$\theta' \leftarrow \arg \max_{\theta'} \sum_t \mathbb{E}_{s_t \sim p_{\theta}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t|s_t)} [\frac{\pi_{\theta'}(a_t|s_t)}{\pi_{\theta}(a_t|s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t)]]$$
$$-\lambda(D_{KL}(\pi_{\theta'}(a_t|s_t) \parallel \pi_{\theta}(a_t|s_t)) - \epsilon)$$

1. 优化上式, 更新 $\theta'$
2. 更新  $\lambda \leftarrow \lambda + \alpha(D_{KL}(\pi_{\theta'}(a_t|s_t) \parallel \pi_{\theta}(a_t|s_t)) - \epsilon)$

# Natural Policy Gradient

schemes. The natural policy gradient (Kakade, 2002) can be obtained as a special case of the update in Equation (12) by using a linear approximation to  $L$  and a quadratic approximation to the  $\bar{D}_{\text{KL}}$  constraint, resulting in the following problem:

$$\underset{\theta}{\text{maximize}} \left[ \nabla_{\theta} L_{\theta_{\text{old}}}(\theta) \Big|_{\theta=\theta_{\text{old}}} \cdot (\theta - \theta_{\text{old}}) \right] \quad (17)$$

$$\text{subject to } \frac{1}{2}(\theta_{\text{old}} - \theta)^T A(\theta_{\text{old}})(\theta_{\text{old}} - \theta) \leq \delta,$$

where  $A(\theta_{\text{old}})_{ij} =$

$$\frac{\partial}{\partial \theta_i} \frac{\partial}{\partial \theta_j} \mathbb{E}_{s \sim \rho_{\pi}} [D_{\text{KL}}(\pi(\cdot|s, \theta_{\text{old}}) \parallel \pi(\cdot|s, \theta))] \Big|_{\theta=\theta_{\text{old}}}.$$

The update is  $\theta_{\text{new}} = \theta_{\text{old}} + \frac{1}{\lambda} A(\theta_{\text{old}})^{-1} \nabla_{\theta} L(\theta) \Big|_{\theta=\theta_{\text{old}}}$ ,

# TRPO的原理



Line search  
(like gradient ascent)



Optimization in Trust Region




03

# 策略改进的 单调性保证

# 策略改进的单调性保证

$$J(\theta') \geq L_{\theta}(\theta') - C \cdot D_{KL}^{max}(\theta, \theta'), \text{ where } C = \frac{4\epsilon\gamma}{(1-\gamma)^2}, \epsilon = \max_{s,a} |A_{\pi}(s, a)|$$

$$L_{\theta}(\theta') = J(\theta) + \sum_t \mathbb{E}_{s_t \sim p_{\theta}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t|s_t)} [\frac{\pi_{\theta'}(a_t|s_t)}{\pi_{\theta}(a_t|s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t)]]$$











04

实验结果

# 训练曲线



## 结果比较

	<i>B. Rider</i>	<i>Breakout</i>	<i>Enduro</i>	<i>Pong</i>	<i>Q*bert</i>	<i>Seaquest</i>	<i>S. Invaders</i>
Random	354	1.2	0	−20.4	157	110	179
Human (Mnih et al., 2013)	7456	31.0	368	−3.0	18900	28010	3690
Deep Q Learning (Mnih et al., 2013)	4092	168.0	470	20.0	1952	1705	581
UCC-I (Guo et al., 2014)	5702	380	741	21	20025	2995	692
TRPO - single path	1425.2	10.8	534.6	20.9	1973.5	1908.6	568.4
TRPO - vine	859.5	34.2	430.8	20.9	7732.5	788.4	450.2

# 推荐阅读

## PPO

### ▣ TRPO的不足

- 近似带来误差
- 求解约束优化问题的困难

### ▣ PPO算法

- 理论更简洁，操作更简单，实验效果更好
- 推荐阅读 Proximal Policy Optimization Algorithms, [John Schulman](#), et al. (2017)



John Schulman

Research Scientist, OpenAI

Verified email at openai.com - [Homepage](#)


[Artificial Intelligence](#) [Robotics](#) [Neuroscience](#)

FOLLOW

Google Scholar

Cited by

	All	Since 2017
Citations	35222	34267
h-index	42	41
i10-index	58	57



TITLE

CITED BY

YEAR

#### Proximal policy optimization algorithms

J Schulman, F Wolski, P Dhariwal, A Radford, O Klimov  
arXiv preprint arXiv:1707.06347

7028

2017

#### Trust region policy optimization

J Schulman, S Levine, P Abbeel, M Jordan, P Moritz  
International conference on machine learning, 1889-1897

4720

2015



# **近端策略优化**

## **Proximal Policy Optimization**

# 回顾TRPO

- TRPO使用KL散度约束策略更新的幅度

$$\theta' \leftarrow \arg \max_{\theta'} \sum_t \mathbb{E}_{s_t \sim p_{\theta}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t|s_t)} [\frac{\pi_{\theta'}(a_t|s_t)}{\pi_{\theta}(a_t|s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t)]]$$

such that  $D_{KL}(\pi_{\theta'}(a_t|s_t) \parallel \pi_{\theta}(a_t|s_t)) \leq \epsilon$

- 使用constraint violate as penalty

$$\theta' \leftarrow \arg \max_{\theta'} \sum_t \mathbb{E}_{s_t \sim p_{\theta}(s_t)} [\mathbb{E}_{a_t \sim \pi_{\theta}(a_t|s_t)} [\frac{\pi_{\theta'}(a_t|s_t)}{\pi_{\theta}(a_t|s_t)} \gamma^t A^{\pi_{\theta}}(s_t, a_t)]]$$
$$-\lambda(D_{KL}(\pi_{\theta'}(a_t|s_t) \parallel \pi_{\theta}(a_t|s_t)) - \epsilon)$$

1. 优化上式, 更新 $\theta'$
2. 更新  $\lambda \leftarrow \lambda + \alpha(D_{KL}(\pi_{\theta'}(a_t|s_t) \parallel \pi_{\theta}(a_t|s_t)) - \epsilon)$

## TRPO的不足

- 重要性比例带来的大方差
- 求解约束优化问题的困难

# PPO: Proximal Policy Optimization



## PPO在TRPO基础上的改进

### 1. 截断式优化目标

conservative  
policy iteration

$$L^{CPI}(\theta) = \hat{\mathbb{E}}_t \left[ \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \hat{A}_t \right] = \hat{\mathbb{E}}_t [r_t(\theta) \hat{A}_t]$$

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)]$$



构建下界

$$L^{CLIP}(\theta) \leq L^{CPI}(\theta)$$

在  $r = 1$  附近相等

$$L^{CLIP}(\theta) = L^{CPI}(\theta)$$

# PPO: Proximal Policy Optimization

## PPO在TRPO基础上的改进

### 1. 截断式优化目标

conservative  
policy iteration

$$L^{CPI}(\theta) = \hat{\mathbb{E}}_t \left[ \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \hat{A}_t \right] = \hat{\mathbb{E}}_t [r_t(\theta) \hat{A}_t]$$

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)]$$

### 2. 优势函数 $\hat{A}_t$ 选用多步时序差分

$$\hat{A}_t = -V(s_t) + r_t + \gamma r_{t+1} + \dots + \gamma^{T-t+1} r_{T-1} + \gamma^{T-t} V(s_T)$$

- 在每次迭代中，并行 $N$ 个actor收集 $T$ 步经验数据
- 计算每步的 $\hat{A}_t$ 和 $L^{CLIP}(\theta)$ ，构成mini-batch
- 更新参数 $\theta$ ，并更新 $\theta_{\text{old}} \leftarrow \theta$



# PPO: Proximal Policy Optimization

## PPO在TRPO基础上的改进

### 3. 自适应的KL惩罚项参数

$$L^{KL PEN}(\theta) = \hat{\mathbb{E}}_t \left[ \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \hat{A}_t - \beta \text{KL}[\pi_{\theta_{\text{old}}}(\cdot|s_t)|\pi_{\theta}(\cdot|s_t)] \right]$$

动态调整 $\beta$ 方法

- 计算KL值  $d = \hat{\mathbb{E}}_t [\text{KL}[\pi_{\theta_{\text{old}}}(\cdot|s_t)|\pi_{\theta}(\cdot|s_t)]]$ 
  - a) 如果  $d < d_{\text{targ}}/1.5$ , 更新  $\beta \leftarrow \beta/2$
  - b) 如果  $d > d_{\text{targ}} \times 1.5$ , 更新  $\beta \leftarrow \beta \times 2$

注：这里1.5和2是经验参数，算法效能和它们并不是很敏感

# PPO实验对比

No clipping or penalty:

$$L_t(\theta) = r_t(\theta)\hat{A}_t$$

Clipping:

$$L_t(\theta) = \min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta)), 1 - \epsilon, 1 + \epsilon)\hat{A}_t$$

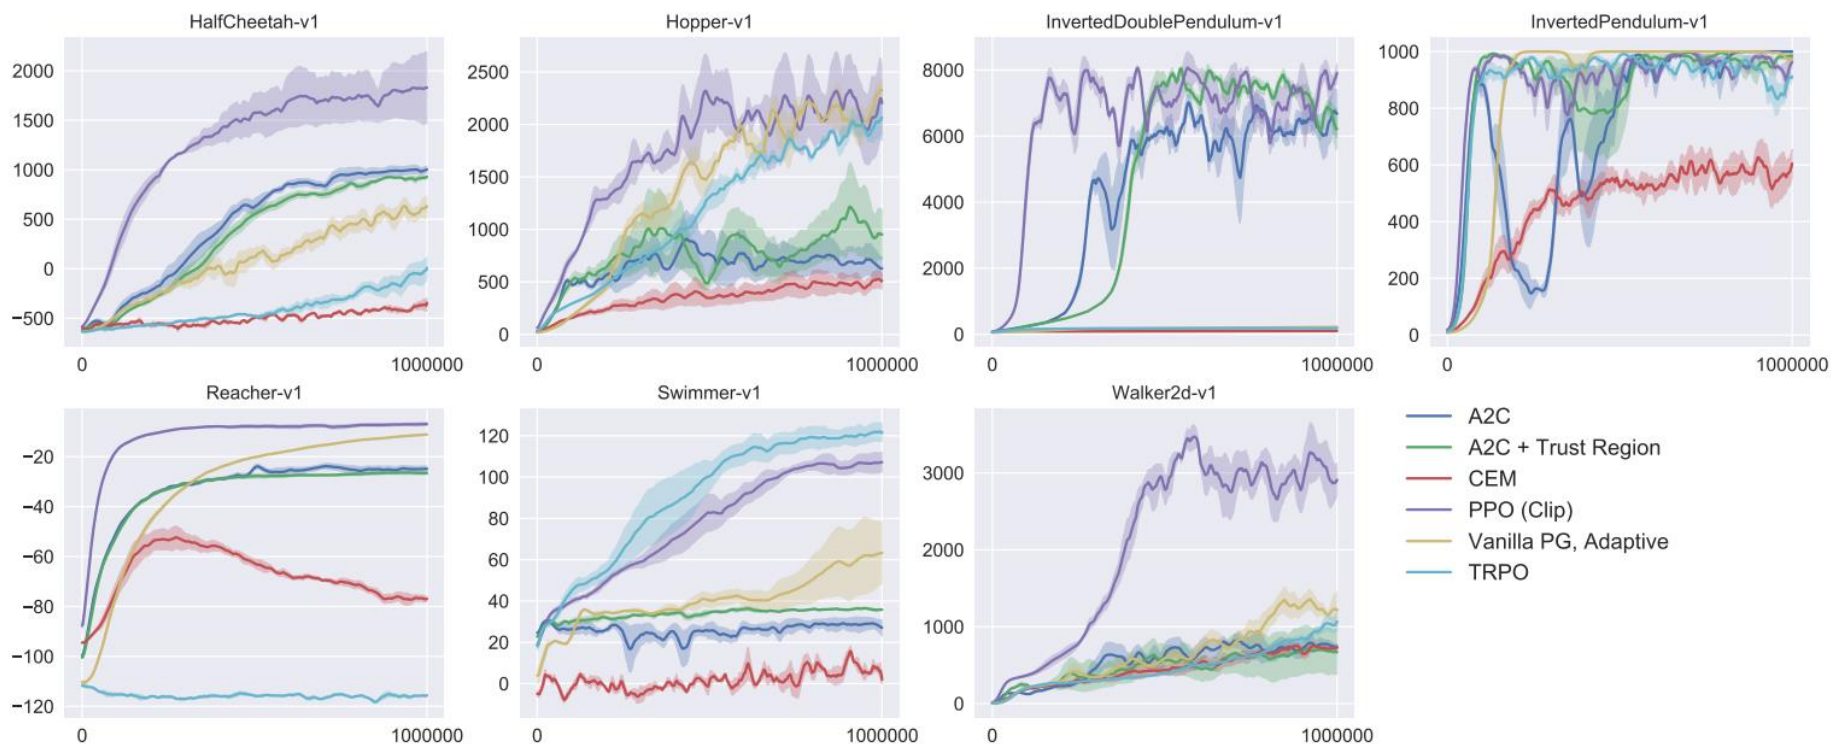
KL penalty (fixed or adaptive)

$$L_t(\theta) = r_t(\theta)\hat{A}_t - \beta \text{KL}[\pi_{\theta_{\text{old}}}, \pi_{\theta}]$$

- 7个连续控制的环境
- 3个random seed
- 每个算法跑100个 episode, 跑21遍, 做平均值计算
- 最佳score归一化为1

algorithm	avg. normalized score
No clipping or penalty	-0.39
Clipping, $\epsilon = 0.1$	0.76
<b>Clipping, <math>\epsilon = 0.2</math></b>	<b>0.82</b>
Clipping, $\epsilon = 0.3$	0.70
Adaptive KL $d_{\text{targ}} = 0.003$	0.68
Adaptive KL $d_{\text{targ}} = 0.01$	0.74
Adaptive KL $d_{\text{targ}} = 0.03$	0.71
Fixed KL, $\beta = 0.3$	0.62
Fixed KL, $\beta = 1.$	0.71
Fixed KL, $\beta = 3.$	0.72
Fixed KL, $\beta = 10.$	0.69

# PPO实验对比



# 总结深度策略梯度方法

- 相比价值函数学习最小化TD误差的目标，策略梯度方法直接优化策略价值的目标更加贴合强化学习本质目标
- 基于神经网络的策略在优化时容易因为一步走得太大会变得很差，进而下一轮产生很低质量的经验数据，进一步无法学习好
- Trust Region一类方法限制一步更新前后策略的差距（用KL散度），进而对策略价值做稳步地提升
- PPO在TRPO的基础上进一步通过限制importance ratio的range，构建优化目标的下界，进一步保证优化的稳定效果，是目前最常用的深度策略梯度算法
- 针对连续动作的决定性策略，可以从构建的critic中直接回传梯度到动作上，然后通过链式法则进一步将梯度回传到策略网络中
- 分布式的actor-critic算法能够充分利用多核CPU资源采样环境的经验数据，利用GPU资源异步地更新网络，这有效提升了DRL的训练效率

**THANK YOU**